


Redes Neurais Convolucionais (CNN)


Guillermo Cámara Chávez

Rede Neural Artificial




Rede Neural Artificial

$$\text{Total Parameters} = (16 \times 4 + 4) + (4 \times 1 + 1) = 73$$




Redes Neural Convolucional

$$\text{Total Parameters} = (4 \times 4 + 4) + (4 \times 1 + 1) = 25$$





Redes Neural Convolucional



NB: only “green” connections shown for simplicity.

Redes Neural Convolucional

- Inspirada no funcionamento do cérebro (córtex visual).
- Uma CNN é adaptada para explorar a **correlação espacial** existente em **imagens**.



Inícios


- Pouco depois, seguiu-se um avanço no reconhecimento de imagem usando algumas melhorias inteligentes para
 - tornar o treinamento mais eficiente
 - extrair recursos locais (e melhorar a dependência de recursos de captura)

by


- Weight sharing
- Pooling

LeCun, Y., Boser, B., Denker, J. S., Henderson, D., Howard, R. E., Hubbard, W., & Jackel, L. D. (1989). Backpropagation applied to handwritten zip code recognition. *Neural computation*, 1(4), 541-551.

(the origin of Convolutional Neural Networks and MNIST)



Redes Neural Convolucional



Conceitos e Operações


- Conceitos
 - campos receptivos locais (*local receptive fields*),
 - mapas de características (*feature maps, activation maps*),
 - compartilhamento de pesos (*shared weights*).
- Operações
 - convolução (*convolution*), subamostragem (*subsampling, pooling*), zero-padding.

Conceitos e Operações

- Neurônios em uma CONV utilizam conectividade local (em vez de conectividade global)
 - i.e, cada neurônio está conectado a uma região contígua de unidades da camada anterior.
- Essa região é o campo receptivo local dessa unidade.

Conceitos e Operações

- Por meio de seu campo receptivo, cada neurônio pode detectar características visuais elementares ...
 - e.g., arestas orientadas, extremidades, cantos
- ...que podem então ser combinadas por camadas subsequentes para detectar características visuais mais complexas.
 - e.g., olhos, bicos, rodas, etc.




Operação de convolução

- O tipo de camada principal em uma CNN é a camada de convolução (*convolution layer*, CONV).
- Cada neurônio em uma CONV aplica um operador de convolução (*filter, kernel*) sobre seu campo receptivo.
 - Um operador de convolução é uma matriz!
- Objetivo: **extrair características (*features*) da imagem de forma automática durante o treinamento.**


Operação de convolução

- No contexto de uma CNN, a aplicação de uma convolução corresponde a computar o produto escalar (*dot product*) entre a entrada e o filtro.
- Resultado: outra matriz!
 - mapa de ativação (*activation map*) ou
 - mapa de características (*feature map*)

Operação de convolução



Operação de convolução



Operação de convolução

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

imagem

1	0	1
0	1	0
1	0	1

operador de convolução
(filtro, kernel)

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0

Image

mapa de
características

4		

Convolved
Feature

Operação de convolução


- Em função do filtro, podem ser extraídas diferentes características da imagem.




CNNs **aprendem** os
filtros
durante o
treinamento!

Operação de convolução

- Um filtro comumente aprendido em uma CNN (nas CONVs iniciais) é o **detector de bordas**.





	0	1	0	
	1	-4	1	
	0	1	0	




Operação de convolução

- Uma CONV é um **arranjo tridimensional (volume)** de neurônios: altura, largura, profundidade.



Operação de convolução




Operação de convolução

- Cada neurônio em uma CONV aplica um filtro (operação de convolução) ao seu campo receptivo.
- Neurônios de uma mesma fatia de profundidade aplicam o mesmo filtro.
 - O objetivo de cada filtro é ativar quando detecta um tipo particular de característica na entrada.

Operação de convolução


- Neurônios de uma mesma coluna de profundidade estão conectados à mesma região da entrada.
 - Idealmente cada fatia irá aprender um tipo de filtro diferente durante o treinamento da CNN.



coluna de
profundidade


Operação de convolução

- Durante a propagação adiante (*forward pass*), cada filtro é aplicado (*convolved*) através do volume de entrada.



Operação de convolução


- O volume de saída de uma CONV é uma sequência de mapas de ativação.




A sequência de mapas de ativação de um volume forma a dimensão de **profundidade** (*depth*) desse volume.

Operação de convolução

- O volume de saída de uma CONV é uma sequência de mapas de ativação.



Operação de convolução




Operação de convolução


- O passo (*stride*, S) é um hiperparâmetro que controla de que forma o filtro é “deslizado” pelo volume de entrada durante a convolução.

$S = 1$

7 x 7 Input Volume




5 x 5 Output Volume




$S = 2$

7 x 7 Input Volume



3 x 3 Output Volume



Operação de convolução


- Zero-padding: exemplo

35	19	25	6
13	22	16	53
4	3	7	10
9	8	1	3

0	0	0	0	0	0
0	35	19	25	6	0
0	13	22	16	53	0
0	4	3	7	10	0
0	9	8	1	3	0
0	0	0	0	0	0

Operação de convolução

- Zero-padding: exemplo




Operação de convolução

- Para um volume de entrada $W \times H \times D$, um filtro de tamanho F , com passo S e *padding* P , a quantidade de neurônios em uma fatia do volume de saída é


$$(W - F + 2P)/S + 1$$

- Exemplos:
 - Com entrada 7x7 e filtro 3x3 com passo 1 e pad 0, a saída teria 5x5 neurônios por fatia.
 - Com $S=2$, teríamos saída com 3x3 neurônios por fatia.


Operação de convolução




Operação de convolução




Operação de convolução




Operação de convolução




Operação de convolução




Operação de convolução




Operação de convolução




Operação de convolução




Operação de convolução




Operação de convolução




Operação de convolução




Operação de convolução



No padding, no strides




Arbitrary padding, no
strides




Half padding, no strides


Operação de convolução



No padding, strides




Padding, strides




Full padding, no strides

Operação de convolução - Dilatation




No padding, no stride, dilatation

Operação de convolução - Group




Using Regular Convolution



Using Group Convolution

Operação de convolução - Group



Principais conceitos por trás da CNNs


- **Conectividade esparsa:** um único elemento no mapa de características está conectado a apenas uma pequena região de pixels. Isso é muito diferente de conectar-se a toda a imagem de entrada, em MLP
- **Compartilhamento:** Os mesmos pesos são usados por diferentes regiões na imagem de entrada
- **Várias camadas:** combinando padrões locais extraídos com padrões globais

Compartilhamento de pesos

- Usado em CONVs para controlar o número de parâmetros da CNN.
- Premissa: se um filtro é útil para detecção em uma região $(x1, y1)$, então ele também é útil para detecção em outra região $(x2, y2)$.

Compartilhamento de pesos

Features of X



Compartilhamento de pesos


Filters to Detect X Features

filters

1	-1	-1
-1	1	-1
-1	-1	1

1	-1	1
-1	1	-1
1	-1	1

-1	-1	1
-1	1	-1
1	-1	-1



Camada de Pooling


- Por vezes encontrada entre duas camadas CONVs sucessivas para reduzir a complexidade do modelo (mitigar sobreajuste).
- Objetivo: reduzir dimensões espaciais (largura x altura) do volume de entrada para a próxima CONV.
 - Aplicada a cada fatia de profundidade do volume de entrada.
 - Profundidade do volume de saída igual à do volume de entrada.

Camada de Pooling

- Entrada: um volume de dimensões $W_1 \times H_1 \times D_1$
- Requer dois hiperparâmetros:
 - a extensão espacial, F
 - o passo (stride), S
- Produz um volume de dimensões $W_2 \times H_2 \times D_2$ onde
 - $W_2 = (W_1 - F) / S + 1$
 - $H_2 = (H_1 - F) / S + 1$
 - $D_2 = D_1$

Camada de Pooling

$S = 2, F = 2,$
 $W_1 = 224, H_1 = 224$
 $D_1 = 64$



$W_2 = 112, H_2 = 112$
 $D_2 = 64$

Camada de Pooling

$(S = 2, F = 2, W_1 = 4, H_1 = 4)$

21	8	8	12
12	19	9	7
8	10	4	3
18	12	9	10

$$W_2 = (W_1 - F) / S + 1$$
$$H_2 = (H_1 - F) / S + 1$$

$W_2 = 2, H_2 = 2$

avg pooling

15	9
12	7

max pooling


21	12
18	10

Imagem reproduzida do material disponibilizado na disciplina cs231n (<http://cs231n.stanford.edu/>)


Spatial dropout

- Problema com *dropout* regular e CNNs: Pixels adjacentes são provavelmente altamente correlacionados (assim, podem não ajudar a reduzir a "dependência" tanto quanto originalmente pretendido por *dropout*)
- Portanto, pode ser melhor descartar mapas de características inteiros

Dropout




Original network



Network with some nodes dropped out


Spatial dropout

Regular Dropout



(a)

Spatial Dropout




(b)

Arquitetura típica

- Em uma CNN, encontramos um ou mais **estágios**, cada qual composto por camadas:
 - de convolução (CONV),
 - de subamostragem (POOL),
 - de normalização de contraste,
- Ao final, é comum encontrar uma ou mais camadas completamente conectadas seguida de camada softmax (módulo de classificação).

Arquitetura típica



LeNet-5