




Aprendizado de Máquina

Guillermo Cámara-Chávez

Aprendizado de Máquina



- Herbert Alexander Simon:
“Aprendizado é qualquer processo pelo qual um sistema melhora sua performance pela experiência.”



Aprendizado de Máquina



- Arthur Samuel:
“Campo de estudo que dá aos computadores a capacidade de aprender sem serem explicitamente programados.
- Tom Mitchell:
Um programa de computador aprende com a experiência E em relação a alguma tarefa T e alguma medida de desempenho P se seu desempenho em T , medido por P , melhora com a experiência E .

Aprendizado de Máquina



- **Aprendizagem = melhora com a experiência em alguma tarefa**
 - Melhora na tarefa **T**
 - Com respeito a uma medida de desempenho **P**
 - Baseado na experiência **E**

Filtro de Spam



- Spam (*Sending and Posting Advertisement in Mass*)
 - todo email que um usuario não quer receber e não autorizou
- T: identificar emails Spam
- P: porcentagem de emails corretamente filtrados
- E: uma base de dados de emails que foram rotulados pelo usuario.

¿Por qué agora?



- Grande disponibilidade de dados
 - Especialmente com o advento da internet
- Incremento do poder computacional
- Progresso crescente de:
 - Algoritmos disponíveis
 - Teoria desenvolvida por pesquisadores
- Aumento no suporte/apoio das indústrias

¿Por qué ahora?



Exemplos



- Imagine escrever um programa de computador que:

- Reconheça pessoas pela face

- **Problemas:**

- Diferentes expressões faciais
- Alterações no rosto (ex. óculos, bigodes)
- Cortes de cabelo
- Etc.

Que características considerar??




Seres humanos: aprendizagem do que deve ser observado depois de vários exemplos

Exemplos



Celebrities Dataset: <http://mmlab.ie.cuhk.edu.hk/projects/CelebA.html>



Liu, Z., Luo, P., Wang, X., & Tang, X. (2015). Deep learning face attributes in the wild. In Proceedings of the IEEE International Conference on Computer Vision (pp. 3730-3738).

Exemplos



<https://docs.microsoft.com/en-us/windows-hardware/design/device-experiences/windows-hello-face-authentication>

Biometria por reconhecimento facial



<https://support.apple.com/en-ph/HT208108>

Exemplos



- Imagine agora escrever programas de computadora para:
 - Responder a **perguntas** sobre vendas como:
 - Quais produtos são vendidos em conjunto?
 - Qual produto recomendar para um cliente?
 - Cómo agrupar clientes para melhorar marketing?



NETFLIX

amazon


LUU, Minh-Duc; LIM, Ee-Peng. Do your friends make you buy this brand?. Data Mining and Knowledge Discovery, vol 32, n 2, p. 287–319, 2018.

Aprendizado de Máquina



- Indução:
 - permite obter conclusiones a partir de um conjunto de exemplos
 - O conceito é aprendido realizando inferência indutiva a partir dos exemplos apresentados (**cuidado na seleção dos exemplos**)
- Dedução:
 - Humanos usam o raciocínio dedutivo para deduzir novas informações a partir de informações logicamente relacionadas.

Aprendizado de Máquina



Aprendizagem




- Supervisionada
 - Neste tipo de aprendizagem existe um "professor" que avalia a resposta do classificador.
- Não Supervisionada
 - Nesta forma de aprendizagem não existe "professor". O clusterizador tem de descobrir sozinho relações, padrões, regularidades ou categorias nos dados que lhe vão sendo apresentados.

Aprendizagem




Supervised Learning in ML



Aprendizagem



Unsupervised Learning in ML



Conjunto de dados



- Estruturados
 - Mais facilmente analisados por algoritmo de AM
 - Exemplo: planilhas e tabelas de atributo-valor
- Não estruturados
 - Mais facilmente analisados por seres humanos
 - Exemplo: imagens, sequência de DNA, textos, páginas web, emails, mensagens
 - Antes do seu uso por algoritmos de AM, são convertidos para estruturados

Dados não estruturados



Girafa



Zebra

Dados estruturados




500	110	Manchas	Girafa
440	90	Manchas	Girafa
240	45	Listas	Zebra
520	115	Manchas	Girafa
260	50	Listas	Zebra
230	50	Listas	Zebra

Definições



- Conjunto de exemplos: é o conjunto contendo valores de atributos, assim como a classe associada



Definições



- Exemplo: dado ou registro
- Atributo: descreve uma característica ou aspecto de um exemplo
- Classe/Rotulo/Etiqueta: identifica a categoria de um atributo
- Modo de aprendizagem
 - Não incremental: todo o conjunto de treinamento presente na aprendizagem
 - Incremental: quando novos exemplos de treinamento são adicionados

Definições



- *Overfitting*:
 - é possível que o classificador faça previsões muito específicas para o conjunto de treinamento
 - O desempenho no conjunto de treinamento é muito bom, mas muito ruim no conjunto de testes
- *Underfitting*:
 - O ajuste é muito ruim para o conjunto de treinamento

Definições



Definições



Dominio

- O domínio $\mathcal{D}$ consiste de dois componentes: o espaço de características ($\mathcal{X}$) e a distribuição de probabilidade marginal $\mathcal{P}(\mathcal{X})$, onde $\mathcal{X} = \{x_1, x_2, \dots, x_n\} \in \mathcal{X}$



Medicina (melanoma)



Cidade/Predios históricos



Satélite

Definições



Dominio



Dominio A: mundo real



Dominio B: imagens sintéticas

Definições



Tarefa (*Task*)

Dado um domínio específico $\mathcal{D}$, uma tarefa consiste em dois componentes: uma classe/rótulo $\mathcal{Y}$ e uma função objetivo $f(\cdot)$, que é aprendida a partir de um conjunto de treinamento (pares $\{x_i, y_i\}$ onde $x_i \in \mathcal{X}$ y $y_i \in \mathcal{Y}$).

Essa função $f(\cdot)$ pode ser usada para prever o rótulo correspondente a uma nova instância de x

Definições




Labeled Data





Lables




Model Training



Prediction



Test Data



Dog

Cat

Como dividir os dados?




- Dados de **treinamento**: usado para treinar o modelo.
- Dados de **validação**: usado para comparação de diferentes modelos e hiperparâmetros.
- Dados de **teste**: usado para comprovar que aquele modelo realmente funciona. São dados ignorados no treinamento e no processo de escolha de hiperparâmetros.

Validação Cruzada




- Crie k partições aleatórias do conjunto de dados com o mesmo tamanho
- Para $j = 1, \dots, k$, faça
 1. Treine o modelo em todos os blocos, exceto o bloco j
 2. Teste o modelo no bloco j
 3. Estime o erro em cada bloco j
- Calcule a média de erros

Validação Cruzada




Classificadores Lineares




• denotes +1

◦ denotes -1




How would you
classify this data?

Classificadores Lineares




$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \mathbf{x} + b)$$

• denotes +1
○ denotes -1



How would you
classify this data?


Classificadores Lineares



$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \mathbf{x} + b)$$


• denotes +1

○ denotes -1



How would you
classify this data?


Classificadores Lineares



• denotes +1


○ denotes -1

$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \mathbf{x} + b)$$



Any of these
would be fine..


..but which is
best?




• denotes +1
○ denotes -1

$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \mathbf{x} + b)$$

How would you
classify this data?




Misclassified
to +1 class



$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \mathbf{x} + b)$$


• denotes +1

○ denotes -1



Define the **margin** of a linear classifier as the width that the boundary could be increased by before hitting a datapoint.


Maximum Margin



1. Maximizing the margin is good according to intuition and PAC theory
2. Implies that only support vectors are important; other training examples are ignorable.
3. Empirically it works very very well.

• denotes +1
○ denotes -1

Support Vectors
are those
datapoints that
the margin
pushes up
against



linear classifier
with the, um,
maximum margin.

This is the
simplest kind of
SVM (Called an
LSVM)

Linear SVM

Avaliação de modelos binários



$$Acc(f) = 1 - err(f)$$

$$err(f) = \frac{1}{n} \sum_{i=1}^n I(y_i \neq f(x_i))$$

$$I(a) = \begin{cases} 1, & \text{se } a = \text{true} \\ 0, & \text{se } a = \text{false} \end{cases}$$

Avaliação de modelos binários



- A acurácia é a proporção entre os exemplos que o modelo classificou corretamente e o número total de exemplos classificados
- Ou seja, número de acertos / total de exemplos

$$Acc = \frac{VP + VN}{total}$$



Avaliação de modelos binários



- O que nos diz a acurácia?
 - Indica o quanto está acertando o modelo em cada uma das classes
- A matriz de confusão representa o acerto e erro por classe

		Valor Predito	
		Sim	Não
Real	Sim	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (TN)

Avaliação de modelos



Avaliação de modelos binários



- Erro e acuracia (*accuracy*)

$$Acc(f) = \frac{VP + VN}{total}$$

$$err(f) = \frac{FP + FN}{total}$$

$$total = VP + FP + VN + FN$$

Avaliação de modelos binários



- TFN (Taxa de Falsos Negativos): proporção de exemplos + classificados incorrectamente
- TFP: (Taxa de Falsos Positivos): proporção de exemplos – classificados incorrectamente

$$err_+ = \frac{FN}{VP + FN}$$

$$err_- = \frac{FP}{VN + FP}$$


Avaliação de modelos binários



- **Precisão:** dentro dos preditos como +, qual é a proporção de corretos
- **Revocação:** Taxa de acerto na classe +

$$prec(f) = \frac{VP}{VP + FP}$$

$$recall(f) = \frac{VP}{VP + FN}$$



Precisão = $\frac{\text{Verdadeiros positivos}}{\text{Verdadeiros positivos} + \text{Falsos positivos}}$

"Quantos elementos selecionados são relevantes?"

Revocação = $\frac{\text{Verdadeiros positivos}}{\text{Verdadeiros positivos} + \text{Falsos negativos}}$

"Quantos elementos relevantes foram selecionados?"

Avaliação de modelos binários



- **Especificidade**
 - Complemento da TFP: taxa de acerto na classe negativa

$$espec(f) = \frac{VN}{VN + FP} = 1 - TFP(f)$$

Avaliação de modelos binários




- **F1-score**
 - Média harmónica entre *precision* e *recall*

$$F_1 = 2 * \frac{prec(f).recall(f)}{prec(f) + recall(f)}$$

Avaliação de modelos binários





- **Área sobre a curva (AUC) ROC** – relação entre TFP e TVP



Avaliação de modelos binários





- **Área sobre a curva (AUC) ROC** – relação entre TFP e TVP



Avaliação de modelos binários





- **Área sobre a curva (AUC) ROC** – relação entre TFP e TVP



Avaliação de modelos binários



- **Área sobre a curva (AUC) ROC** – relação entre TFP e TVP



Classificación multiclasse



- Podemos utilizar medidas de classificação binaria na classificação multiclasse

Macro vs. micro average

Boas práticas em ML



- Considere o seguinte exemplo, um exemplo de classificação binaria com:
 - 99 exemplos da classe positiva
 - 1 exemplo da classe negativa
- Considere que o classificador classificou corretamente todos os exemplos da classe positiva e errou na classe negativa
- Neste caso temos uma taxa de sucesso de 99%?
- A taxa de acerto de um classificador nem sempre é a melhor medida, especialmente com classes desequilibradas.

Classificação multiclasse



- Encontrar a acurácia macro e micro para esses resultados

		Classe predita		
		1	2	3
Classe verdadeira	1	11	1	3
	2	1	4	0
	3	2	1	6

$$macro = \frac{(11 + 4 + 6)}{(11 + 4 + 6 + 1 + 3 + 1 + 2 + 1)} = 0.72$$

$$micro = \frac{\frac{11}{(11+1+3)} + \frac{4}{(1+4)} + \frac{6}{(2+1+6)}}{3} = 0.73$$