



Representação e Descrição

Guillermo Cámara-Chávez

Introdução



- Objetos ou Segmentos são representados como uma coleção de pixels em uma imagem
- Para o reconhecimento do objeto é necessário descrever as propriedades dos grupos de pixels
- A descrição é muitas vezes apenas um conjunto de números que são chamados de “**descritores do objeto**”

Introdução



- Segmentos ou Objetos de uma imagem possuem fundamentalmente as propriedades relativas:
 - Forma
 - Cor
 - Textura

Introdução



- A medida de qualquer destas propriedades é denominada de Características ou Descritor
- Estas características podem formar um vetor de escalares, denominado **Vetor de Características**

Introdução



- Descritores:
 - Pode-se reconhecer objetos comparando-se simplesmente os descritores de objetos em uma imagem com os descritores de objetos conhecidos
- Os descritores devem ter quatro propriedades importantes
 1. Devem definir um conjunto completo. Dois objetos devem ter os mesmos descritores se e somente se eles tiveram as mesmas características.

Introdução



2. Devem ser congruentes. Deve-se reconhecer objetos como similares quando estes objetos têm descritores semelhantes
3. Devem ter propriedades invariantes. Deve ser possível reconhecer objetos independente de rotação, escala, posição e também de transformações afins e perspectiva

Introdução



4. Devem ser um conjunto compacto. Um conjunto de descritores deve representar a essência de um objeto de maneira eficiente

Introdução




- Após a segmentação, os agrupamentos resultantes são usualmente representados e descritos em um formato apropriado
- Trata-se de representar e descrever uma determinada região da imagem de forma apropriada para posterior processamento
- Representa-se em termos de
 - Características externas (fronteira)
 - Características internas (pixels que compõem um região)

Código de cadeia



- Usada para representar fronteiras
- Fronteiras são consideradas sequências conectadas (conectividade de 4 ou 8) de segmentos de linha reta
- A direção de cada segmento é codificada por um esquema de numeração.

Código de cadeia



a b


FIGURE 11.3
Direction
numbers for
(a) 4-directional
chain code, and
(b) 8-directional
chain code.

- Escolhe-se um ponto aleatório na fronteira e percorre-se a mesma no sentido horário.
- Esta abordagem é inapropriada, pois as cadeias resultantes são muito longas e suscetíveis a ruídos

Código de cadeia



- Reamostra-se a fronteira utilizando-se uma grade de espaçamento maior




a b c


FIGURE 11.4

(a) Digital boundary with resampling grid superimposed.
(b) Result of resampling.
(c) 8-directional chain-coded boundary.

Código de cadeia



(a)



(b)

Figura 7.4: Normalização do código da cadeia com respeito à rotação. (a) borda original do objeto, (b) borda após rotação do objeto em 90° .

- Cadeia 1: 44422202006666
- Cadeia 2: 66644424220000

Código de cadeia




- Cadeia 1: 44422202006666
 - Diferença 1 : 0060062606000
- Cadeia 2: 66644424220000
 - Diferença 2 : 0060062606000
- Portanto, esses dois códigos representam a mesma borda.
- Invariância à escala: reamostra-se a grade

Assinaturas



- Uma assinatura é uma **representação funcional unidimensional** de uma fronteira
- **Reduzindo-se** a representação da fronteira a um **domínio unidimensional**, espera-se que a mesma **se torne mais simples de descrever**
- Uma das formas de assinatura mais simples é a dada pela **distância dos pontos da fronteira ao centróide em função do ângulo**.

Assinaturas



a b

FIGURE 11.10

Distance-versus-angle signatures.

In (a) $r(\theta)$ is constant. In (b), the signature consists of repetitions of the pattern


$r(\theta) = A \sec \theta$ for $0 \leq \theta \leq \pi/4$ and $r(\theta) = A \csc \theta$ for $\pi/4 < \theta \leq \pi/2$.

Assinaturas



- A invariância com relação à rotação pode ser obtido pela seleção de um ponto inicial.
 - Uma maneira é escolher o ponto mais distante do centróide
- A invariância com relação à escala pode ser obtida pela normalização dos valores de $r(\vartheta)$

Projeções



- Projeção Vertical
$$h(y) = \sum_y f(x, y)$$
- Projeção Horizontal
$$v(x) = \sum_x f(x, y)$$
- Projeção Diagonal
$$d(t) = \sum_t f(x, y)$$

Descritores de Fronteiras



1. Comprimento da Fronteira (Perímetro)
 - Contagem do número de píxels da Fronteira
 - Usando o código de cadeia:
 - de 4 direções: número de elementos
 - de 8 direções: número de elementos pares (horizontais e verticais) mais $\sqrt{2}$ x (número de elementos ímpares) elementos diagonais

Descritores de Fronteiras




2. Diâmetro da Fronteira:

$$Diam(B) = \max_{i,j} [D(p_i, p_j)]$$

onde: $D(p_i, p_j)$ é a distância entre os píxels i e j sobre a fronteira B

- O valor do Diâmetro e a orientação da linha que conecta os dois pontos da fronteira mais distantes são descritores úteis

Descritores de Fronteiras




- Esta linha é também chamada de Eixo Maior da fronteira

Descritores de Fronteiras



3. Excentricidade da Fronteira

- É a razão entre o Eixo maior (D) e o Eixo Menor (d) da fronteira. $E = D/d$
- Eixo Menor é a maior distância entre dois pontos da fronteira B sobre uma perpendicular ao Eixo Maior
- Usar função **`skimage.measure.regionprops`**




Descritores de Fronteiras



area:	centroid_weighted_local:	image_intensity:	moments_normalized:
area_bbox:	coords:	inertia_tensornd:	moments_weighted:
area_convex:	eccentricity:	inertia_tensor_eigvals:	moments_weighted_central:
area_filled:	equivalent_diameter_area:	intensity_max:	moments_weighted_hu:
axis_major_length:	euler_number:	intensity_mean:	moments_weighted_normalized:
axis_minor_length:	extent:	intensity_min:	orientation:
bbox:	feret_diameter_max:	label:	perimeter:
centroid:	image:	moments:	perimeter_crofton:
centroid_local:	image_convex:	moments_central:	slice:
centroid_weighted:	image_filled:	moments_hu:	solidity:

Descritores de Fronteiras



Descritores de Fronteiras



- Descritores de Fourier
 - São formados pelos coeficientes da transformada discreta de Fourier
 - Expressa as informações globais da curvatura de um objeto
 - Uma sequência de número é obtida a partir do plano cartesiano através das coordenadas do contorno do objeto

Descritores de Fronteiras



- Essas coordenadas podem ser representadas pela função unidimensional definida como:

$$s(k) = x(k) + jy(k)$$

- Sendo que $k = 0, 1, 2, \dots, N-1$ é o número de pontos, x é a coordenada real e y a coordenada imaginária

Descritores de Fronteiras



- A transformada de Fourier para $s(k)$

$$a(u) = \sum_{k=0}^{N-1} s(k) e^{-j2\pi uk / N}$$

- A transformada inversa

$$s(k) = \sum_{u=0}^{N-1} a(u) e^{j2\pi uk / N}$$

Descritores de Fronteiras



```
coord = measure.find_contours(bat_bin, fully_connected='low')
```

```
ncoord = np.empty(shape=[0, 2])
```

```
for contour in coord:
```

```
    ncoord = np.append(ncoord, contour, axis=0)
```

```
z = frdescp(ncoord)
```

```
nz = ifrdescp(z, 20)
```

Descritores de Fronteiras



```
lin, col = bat.shape[:2]
```

```
nimg = bound2img(nz, lin, col)
```


```
nimg2 = bound2img(ncoord, lin, col)
```

```
fig, ax = plt.subplots(1,2,figsize=(10,10))
```


```
ax[0].imshow(nimg2, cmap=plt.cm.gray)
```

```
ax[1].imshow(nimg, cmap='gray')
```


Descritores de Fronteiras



Original



100



10

Descritores Regionais



1. Texturas:

- Fornece medidas de propriedades como suavidade, rugosidade e regularidade
- Abordagens principais: estatística, estrutural, espectral e análise local
- A abordagem estatística caracteriza as texturas como suave, áspera, granular, etc


Descritores Regionais




- Reconhecer o tipo de tecido.
- Segmentar as bordas.



(a)



(b)



(c)

Textura

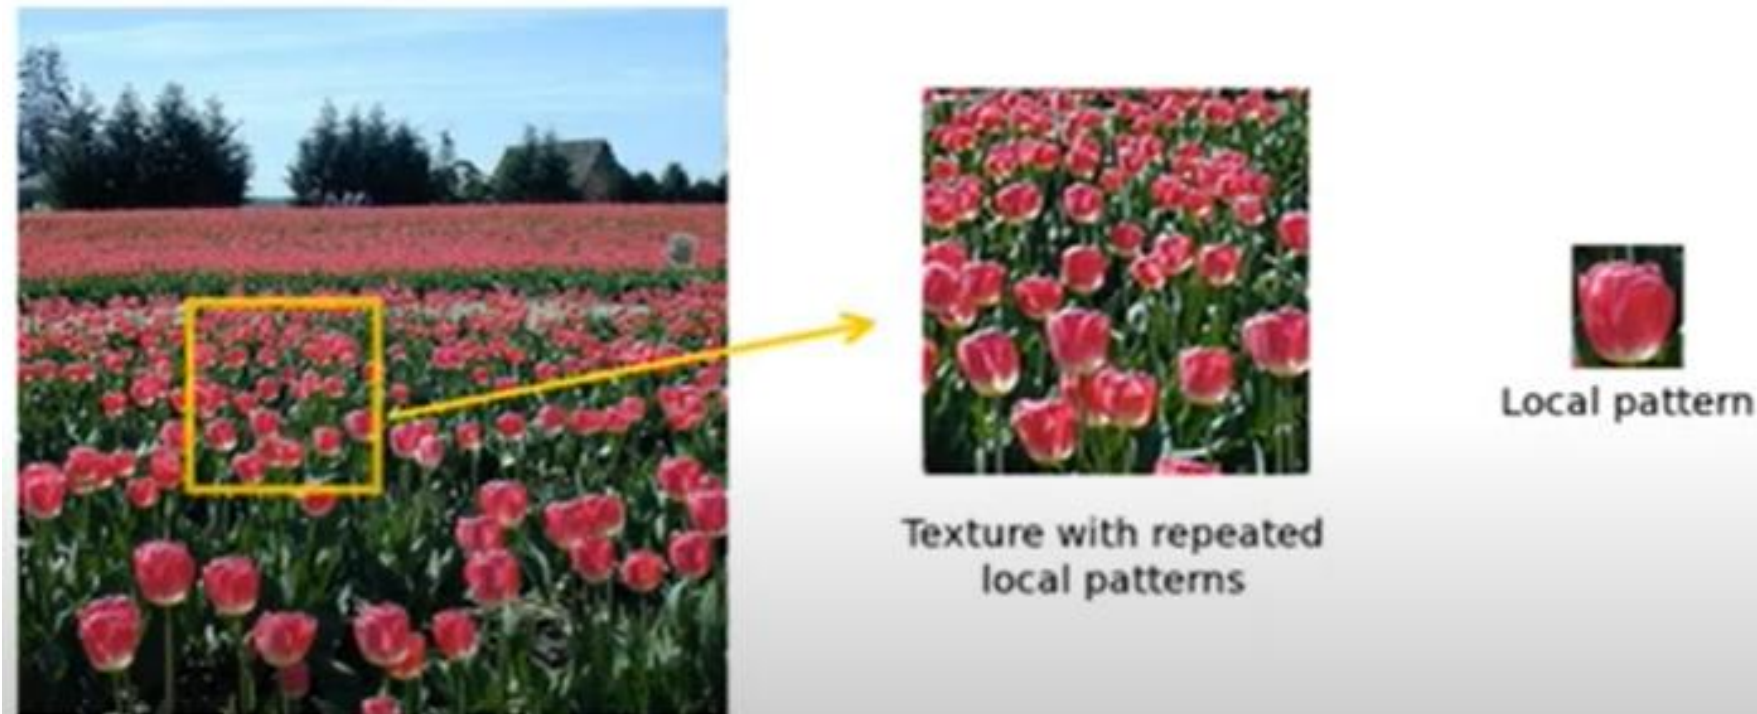


- A textura em imagens é um conceito relacionado com diferenças locais nos níveis de intensidade, onde elementos importantes são:
 - Diferença no níveis dos pixels (contraste)
 - Tamanho das regiões (janela)
 - Direção (ou falta de direção)

Textura



- Representa detalhes em uma imagem




Textura




- Existem dois principais características em texturas

repetição



Estocásticas




Ambas



Textura




- Compare texturas para procurar padrões semelhantes ou diferentes



Análise de textura: abordagens



- Estrutural (top-down)
 - Decompor a imagem em elementos básicos: texels (texture elements)
 - Adequado para textura artificiais ou padrões bem definidos
- Estatístico (bottom-up)
 - Caracterizar a textura como uma serie de propriedades estatísticas em um pequeno grupo de pixels
 - Normalmente adequado pra texturas naturais



Análise de textura: abordagens



- Definir e segmentar as regiões de textels pode ser uma tarefa muito complexa em imagens do mundo real
- Texturas são muito similares, mas é difícil de extrair sua estrutura



Análise de textura: abordagens



- Comparar estatísticas pode ser uma boa alternativa
- Calcular medidas estatísticas para descrever uma textura em imagens em escala de cinza ou coloridas
- Computacionalmente eficiente

Textura: matriz de co-ocorrência



- Captura a relação entre um par de pixels
- A matriz de co-ocorrência considera uma distância fixa Q entre dois pixels: referência e vizinho
- Exemplo: $Q=(0,1)$ significa que o vizinho seja deslocado 0 pixels na direção de x e 1 pixels na direção de y . Neste caso particular, estamos procurando o pixel que está à direita


Textura: matriz de co-ocorrência



- Considere $Q=(0,1)$
- Calcula a coocorrência para cada pixel na imagem com L níveis de cinza
- Construir a matriz G dado um $Q=(dx,dy)$ e todos os pares de intensidades $i, j \in \{0, \dots, L - 1\}$

$$G(i, j) = |\{(x, y) | f(x, y) = i, f(x + dx, y + dy) = j\}|$$

Textura: matriz de co-ocorrência



Considering the configuration of relative position as $Q = (dx, dy) = (0, 1)$:

pixel	n. 0	n. 1	n. 2	n. 3
ref. 0	2	2	1	0
ref. 1	0	4	0	0
ref. 2	0	0	5	2
ref. 3	0	0	0	4

0	0	1	1	1
0	0	1	1	1
0	2	2	2	2
2	2	3	3	3
2	2	3	3	3

Descritores Regionais

Abordagem Estatística

Descriptor	Explanation	Formula
Maximum probability	Measures the strongest response of G . The range of values is $[0, 1]$.	$\max_{i,j}(p_{ij})$
Correlation	A measure of how correlated a pixel is to its neighbor over the entire image. Range of values is 1 to -1 , corresponding to perfect positive and perfect negative correlations. This measure is not defined if either standard deviation is zero.	$\frac{\sum_{i=1}^K \sum_{j=1}^K (i - m_r)(j - m_c)p_{ij}}{\sigma_r \sigma_c}$ $\sigma_r \neq 0; \sigma_c \neq 0$
Contrast	A measure of intensity contrast between a pixel and its neighbor over the entire image. The range of values is 0 (when G is constant) to $(K - 1)^2$.	$\sum_{i=1}^K \sum_{j=1}^K (i - j)^2 p_{ij}$
Uniformity (also called Energy)	A measure of uniformity in the range $[0, 1]$. Uniformity is 1 for a constant image.	$\sum_{i=1}^K \sum_{j=1}^K p_{ij}^2$
Homogeneity	Measures the spatial closeness of the distribution of elements in G to the diagonal. The range of values is $[0, 1]$, with the maximum being achieved when G is a diagonal matrix.	$\sum_{i=1}^K \sum_{j=1}^K \frac{p_{ij}}{1 + i - j }$
Entropy	Measures the randomness of the elements of G . The entropy is 0 when all p_{ij} 's are 0 and is maximum when all p_{ij} 's are equal. The maximum value is $2 \log_2 K$. (See Eq. (11.3-9) regarding entropy).	$-\sum_{i=1}^K \sum_{j=1}^K p_{ij} \log_2 p_{ij}$

Z_i : intensidade dos pixels

$P(z)$: histograma das intensidades

L : número dos possíveis níveis de cinza

Função skimage

feature.graycoprops

Descritores Regionais



4. Momentos

- O momento de ordem $(p+q)$ de uma função contínua bi-dimensional é definido como:

$$m_{pq} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x^p y^q f(x, y) dx dy \quad \text{para } p, q = 0, 1, 2, \dots$$

$$m_{00} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x^0 y^0 f(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy$$

$$m_{00} = \text{área da Região}$$

Descritores Regionais



$$m_{01} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x^0 y^1 f(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} y f(x, y) dx dy$$

$$m_{10} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x^1 y^0 f(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x f(x, y) dx dy$$

m_{01} e m_{10} são as coordenadas do Centro de Massa da Região

Descritores Regionais



Momentos centrais

- São momentos centralizados em regiões e podem ser expresso como:

$$\mu_{pq} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \bar{x})^p (y - \bar{y})^q f(x, y) dx dy$$

Onde: $\bar{x} = \frac{m_{10}}{m_{00}}$ e $\bar{y} = \frac{m_{01}}{m_{00}}$ São as coordenadas do Centro de Massa, normalizadas pela área da região.

Descritores Regionais



- Para uma imagem digital

$$\mu_{pq} = \sum_x \sum_y (x - \bar{x})^p (y - \bar{y})^q f(x, y)$$

Descritores Regionais



Momentos Centrais até a ordem 3:

$$\mu_{00} = \sum_x \sum_y (x - \bar{x})^0 (y - \bar{y})^0 f(x, y) = \sum_x \sum_y f(x, y) = m_{00}$$

Ordem 1

$$\mu_{10} = \mu_{01} = 0$$

Ordem 2

$$\mu_{20} = m_{20} - \bar{x}m_{10}$$

$$\mu_{02} = m_{02} - \bar{y}m_{01}$$

$$\mu_{11} = m_{11} - \bar{y}m_{10}$$

Ordem 3

$$\mu_{12} = m_{12} - 2\bar{y}m_{11} - \bar{x}m_{02} + 2\bar{y}^2m_{10}$$

$$\mu_{21} = m_{21} - 2\bar{x}m_{11} - \bar{y}m_{20} + 2\bar{x}^2m_{01}$$

$$\mu_{30} = m_{30} - 3\bar{x}m_{20} + 2\bar{x}^2m_{10}$$

$$\mu_{03} = m_{03} - 3\bar{y}m_{02} + 2\bar{y}^2m_{01}$$

São Invariantes com relação à escala.

Descritores Regionais



Momentos Invariantes:

- Conjunto de momentos (Momentos Invariantes de Hu) que são relativamente invariantes à translação, rotação e escala.
- Momentos centrais normalizados pela área:

$$\eta_{pq} = \frac{\mu_{pq}}{\mu_{00}^\gamma}$$

Onde:

$$\gamma = \frac{p+q}{2} + 1$$

Para $p+q=2,3,4,\dots$

Momentos Invariantes de Hu:

$$\phi_1 = \eta_{20} + \eta_{02}$$

$$\phi_2 = (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2$$

$$\phi_3 = (\eta_{30} - 3\eta_{12})^2 + (3\eta_{21} - \eta_{03})^2$$


$$\phi_4 = (\eta_{30} + \eta_{12})^2 + (\eta_{21} + \eta_{03})^2$$

$$\phi_5 = (\eta_{30} - 3\eta_{12})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] + \\ (3\eta_{21} - \eta_{03})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2]$$

$$\phi_6 = (\eta_{20} - \eta_{02})[(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] + \\ 4\eta_{11}(\eta_{30} + \eta_{12})(\eta_{21} + \eta_{03})$$

$$\phi_7 = (3\eta_{21} - \eta_{03})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] + \\ (3\eta_{12} - \eta_{30})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2]$$

Descritores Regionais



Descritores Regionais




Invariante (log)	Original	Metade	Espelhado	Rotacionado 2°	Rotacionado 45°
ϕ_1	6,249	6,226	6,919	6,253	6,318
ϕ_2	17,180	16,954	19,955	17,270	16,803
ϕ_3	22,655	23,531	26,689	22,836	19,724
ϕ_4	22,919	24,236	26,901	23,130	20,437
ϕ_5	45,749	48,349	53,724	46,136	40,525
ϕ_6	31,830	32,916	37,134	32,068	29,315
ϕ_7	45,589	48,343	53,590	46,017	40,170

Descritores Regionais



- O conteúdo da imagem é transformada em coordenadas de características locais que são invariantes à translação, rotação e escala.



Descritores Regionais



Local Binary Patterns (LBP)



- Baseia-se no fato de que certos padrões binários locais em uma região vizinha de um pixel são propriedades fundamentais da textura de uma imagem.
- Desta forma, o histograma de ocorrências destas características é um bom descritor de textura.

Local Binary Patterns (LBP)



- O operador $LBP_{P,R}$ produz 2^P padrões binários diferentes que podem ser formados por P pixels na vizinhança.
- (P, R) significa uma vizinhança de P pontos uniformemente distribuídos em um raio R .

Local Binary Patterns (LBP)



- Funcionamiento


$$LBP_{P,R}(x, y) = \sum_{p=0}^{P-1} s(i_p - i) 2^p$$

$$s(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

Local Binary Patterns (LBP)



- Cálculo do LBP




- (a) O pixel central é selecionado limiar.
- (b) A imagem é binarizada com base nesse limiar
- (c) Com base à máscara (c), o valor LBP é calculado

Local Binary Patterns (LBP)



- Note que para uma vizinhança de 8 pixels (2^8) temos um histograma de 256 posições



- Depois, calcula-se o histograma

Histogram of Oriented Gradients (HOG)



- É um descriptor usado para detectar objetos
- O descriptor contabiliza as ocorrências das orientações dos gradientes localizados em regiões da imagem
- Foi criado por Dalal & Triggs para detectar pessoas
- A dimensão do descritor é grande



Histogram of Oriented Gradients (HOG)




- Passos para calcular el HOG
 1. Pre-procesar (redimensionar)
 2. Calcular o gradiente da imagen
 3. Calcular o histograma das orientações dos gradientes em celulas de 8x8
 4. Normalização por bloque
 5. Formar o vector descritor


HOG - Preprocesamento



Parches avaliados são de tamanho 64x128



Original Image : 720 x 475



HOG - Gradientes



Calcular os gradientes horizontais e verticais



-1	0	1
----	---	---

-1
0
1



$$g = \sqrt{g_x^2 + g_y^2}$$

$$\theta = \arctan \frac{g_y}{g_x}$$

HOG – Histograma de Orientaciones



O gradiente de uma célula de 8x8 contém 2 valores (gradiente e magnitude) por cada pixel, gerando em total 128 números





2	3	4	4	3	4	2	2
5	11	17	13	7	9	3	4
11	21	23	27	22	17	4	6
23	99	165	135	85	32	26	2
91	155	133	136	144	152	57	28
98	196	76	38	26	60	170	51
165	60	60	27	77	85	43	136
71	13	34	23	108	27	48	110

Gradient Magnitude

80	36	5	10	0	64	90	73
37	9	9	179	78	27	169	166
87	136	173	39	102	163	152	176
76	13	1	168	159	22	125	143
120	70	14	150	145	144	145	143
58	86	119	98	100	101	133	113
30	65	157	75	78	165	145	124
11	170	91	4	110	17	133	110

Gradient Direction

HOG – Histograma de Orientaciones




Histograma de 9 bins, [0, 180]

HOG – Normalização



- Normalizar o histograma (invariante à iluminação)
- Um bloque de 16x16 pixels (ou também 2x2 células) tem 4 histogramas que são concatenados para formar um vetor de 36 elementos
- Aplica-se a norma L2 para normalizar $|x| = \sqrt{\sum_{k=1}^n |x_k|^2}$
 - Sea el vector [128, 64, 32] $\rightarrow \sqrt{128^2 + 64^2 + 32^2} = 146.64$
 - [128/146.64, 64/146.64, 32/146.64] $\rightarrow$ [0.87, 0.43, 0.22].
 - El vector 2x[128, 64, 32] = [256, 128, 64] = [0.87, 0.43, 0.22]

HOG – Normalização



1. Existem 7 x 15 blocos de 16x16 pixels. Fazendo um total de 105
2. Cada bloco é representado por um vetor de 36x1 (em cada bloco tem 4 histogramas de 9 bins).
3. Concatenando os histogramas, tem-se um descritor de $36 \times 105 = 3780$ elementos.