

Evolução em Processamento de Imagens: Transformers e U-Net

Guillermo Camara Chavez



Do Clássico ao Profundo: Motivação



Métodos Clássicos

Extração manual de características (Filtros, SIFT, HOG) seguida de classificadores simples como SVM. Eficaz para problemas controlados.

Revolução das CNNs

Aprendizado automático de features hierárquicas. Excelente desempenho local, mas limitadas pelo campo receptivo fixo.

O Limite do Contexto

Convoluções lutam para capturar dependências de longo alcance em imagens complexas sem redes extremamente profundas.

Era dos Transformers

Mecanismo de atenção permite modelagem global dinâmica, conectando pixels distantes com a mesma facilidade que vizinhos.

Visão Geral do Transformer (NLP)

Origem

Revolucionária

Proposto por Vaswani et al. (2017) no paper "Attention is All You Need", o Transformer marcou o fim da dominância das redes recorrentes (RNNs/LSTMs) em NLP.

Encoder-Decoder

Arquitetura baseada em Encoder e Decoder puros. Processa a sequência inteira de uma vez (paralelismo), mantendo contexto global imediato.

Atenção é Tudo

Substitui a recorrência pelo mecanismo de Self-Attention, permitindo que cada token na sequência "olhe" e pondere a importância de todos os outros.

Atenção: Q, K, V e Softmax

Conceito de Scaled Dot-Product

- **Q, K, V:** Query (consulta), Key (chave) e Value (conteúdo). A Query busca Keys similares para ponderar os Values.
- **Cálculo de Pesos:** Produto escalar entre Q e K mede a similaridade. Softmax converte em probabilidades (soma 1).
- **Normalização:** Divisão por raiz de d_k estabiliza gradientes.

```
# Scaled Dot-Product Attention
scores = torch.matmul(Q, K.transpose(-2, -1))
scores = scores / math.sqrt(d_k)
attn = F.softmax(scores, dim=-1)
output = torch.matmul(attn, V)
```

Implementação simplificada (PyTorch)

Query, Key e Value (Intuição)

Analogia: Você é um aluno e quer entender melhor uma pergunta.
Você olha para seus colegas para ver quem pode ajudar

- Query: o que quero saber.
- Key: o que cada um sabe.
- Value: a informação oferecida

Query, Key e Value (Intuição)

Como a atenção funciona passo a passo

Para cada palavra:

- 1 Ela cria uma Query
- 2 Compara essa Query com todas as Keys das outras palavras
- 3 Mede o quanto cada palavra é importante
- 4 Usa os Values das palavras importantes
- 5 Cria uma nova representação daquela palavra

Multi-Head Attention

Em vez de realizar uma única função de atenção, o Transformer projeta Q, K e V múltiplas vezes em paralelo.



Visão Paralela

Múltiplas "cabeças" focam em diferentes partes da sequência simultaneamente.



Diversidade

Captura relações distintas (ex: sintaxe vs semântica, local vs global) num só passo.



Fusão

Concatenação e projeção linear final combinam os aprendizados de todas as cabeças.

Positional Encoding

O Dilema da Ordem

Sem recorrência ou convolução, o Transformer processa o conjunto de tokens como uma "sacola de palavras". "Gato persegue Rato" seria idêntico a "Rato persegue Gato" sem injeção explícita de ordem.

Solução Senoidal

O paper original soma ondas de seno e cosseno de diferentes frequências aos embeddings de entrada, criando uma assinatura única para cada posição absoluta.

Encoder: Bloco e Empilhamento



1. Bloco Fundamental

Composto por duas sub-camadas principais: **Multi-Head Attention** (para contexto) e **Feed-Forward Network** (processamento por token).

2. Add & Norm

Conexões residuais (skip) seguidas de Layer Normalization após cada sub-camada são cruciais para treinar redes profundas sem degradação.

3. Empilhamento (Stacking)

O Encoder repete este bloco N vezes (ex: N=6 ou 12), refinando as representações de baixo nível para abstrações complexas.

Decoder: Máscara e Atenção Cruzada

1. Máscara Causal

Impede que o modelo "veja o futuro". Durante o treino, a atenção para posições futuras é zerada ($-\infty$ antes do softmax), garantindo auto-regressão correta.

2. Cross-Attention

Ponto de conexão entre Encoder e Decoder. Aqui, as **Queries** vêm do Decoder, enquanto **Keys** e **Values** vêm do Encoder, integrando a informação da entrada.

3. Geração

O modelo gera um token por vez. A saída do passo t torna-se parte da entrada no passo $t+1$, construindo a sequência progressivamente.

Treinamento e Regularização

Otimização

Uso de otimizadores como AdamW com *Learning Rate Warm-up* é crucial para estabilizar o início do treino.

Regularização

Técnicas agressivas como Dropout Residual e *Label Smoothing* previnem overfitting em modelos com milhões de parâmetros.

Escalabilidade

A arquitetura favorece paralelismo massivo, seguindo leis de escala onde mais dados e computação resultam em melhor performance.

Complexidade e Limitações

O Custo Quadrático

A matriz de atenção conecta todos os tokens entre si. Se a sequência dobra de tamanho (N), o custo computacional quadruplica ($O(N^2)$).

Impacto na Memória

Para imagens, tratar cada pixel como token é inviável (ex: 1080p tem ~2 milhões de pixels). Isso forçou a criação de estratégias como o uso de Patches (ViT) ou Janelas (Swin).

Do Texto à Imagem: Ideia de Tokens

Analogia Palavra-Patch

Em NLP, a unidade é a palavra. Em Visão, o Vision Transformer (ViT) propôs tratar recortes quadrados da imagem (patches) como se fossem "palavras visuais".

Viés Indutivo vs Flexibilidade

CNNs nascem sabendo o que é "vizinhança" (viés forte). Transformers começam "em branco", exigindo mais dados para aprender essas relações, mas sem as amarras locais das CNNs.

Potencial Global

Essa liberdade permite ao Transformer conectar um padrão no canto superior esquerdo com outro no inferior direito na primeira camada, algo impossível para uma CNN rasa.

ViT: Patches como Tokens

1. Grade de Patches

A imagem é dividida em quadrados fixos (ex: 16x16). Cada quadrado é achatado (flatten) e projetado linearmente para virar um vetor de embedding.


2. Token [CLS]

Um token extra aprendível é adicionada à sequência. O estado final deste token após o Encoder serve como a representação global da imagem para classificação.

3. Encoder Puro

Embeddings de posição são somados e a sequência entra num Transformer Encoder padrão. Nenhuma convolução é usada na arquitetura principal.

ViT: Visual Transformer



ViT: Vantagens e Desvantagens

Vantagens 👍

- **Contexto Global:** Captura relações de longo alcance desde a primeira camada.
- **Escalabilidade:** Performance continua subindo com modelos e datasets gigantes (saturation plateau é alto).
- **Robustez:** Menos sensível a texturas locais ou oclusões parciais.

Desvantagens 👎

- **Custo Computacional:** Atenção global é cara para imagens de alta resolução ($O(N^2)$).
- **Ineficiência de Dados:** Treino do zero em datasets pequenos (ex: CIFAR-10) gera resultados medíocres.
- **Ajuste Fino:** Requer cuidado ao mudar resolução de entrada (interpolação posicional).

Swin: Atenção em Janelas

Janelas Locais (W-MSA)

Divide a imagem em janelas (ex: 7x7 patches). A atenção ocorre apenas **dentro** de cada janela, isoladamente.


Shifted Windows (SW-MSA)

Na camada seguinte, as janelas são deslocadas (shifted). Isso cria pontes entre janelas vizinhas, permitindo fluxo de informação global.


Pirâmide Hierárquica

Reduz a resolução espacial progressivamente (Merging Layers), criando uma hierarquia de features similar às CNNs (ResNet).


Swin: Atenção em Janelas




(a) Swin Transformer



(b) Shifted Window



(c) Two Successive Swin Transformer Blocks



(d) Architecture

Swin: Eficiência e Uso Prático

Complexidade Linear $O(N)$

Ao limitar a atenção a janelas locais de tamanho fixo, o custo computacional cresce linearmente com o tamanho da imagem, não quadraticamente.

O Novo Padrão para Visão

Supera CNNs (como EfficientNet) e ViT puro em tarefas densas que exigem alta resolução, como Detecção de Objetos e Segmentação.

O Melhor dos Dois Mundos

Combina a flexibilidade de modelagem de longo alcance dos Transformers com a eficiência de processamento multiescala das CNNs.

Swin: Integração em Modelos

Backbone Universal

Funciona como um substituto "plug-and-play" para backbones ConvNet (ResNet, VGG) em arquiteturas complexas como Mask R-CNN, UperNet e DETR.

Resultados Comprovados

Vencedor do ICCV 2021 Vision Challenge, estabelecendo novos recordes em benchmarks de detecção e segmentação semântica.

U-Net: Conceito

Formato em U Simétrico

Arquitetura icônica em forma de "U", balanceando perfeitamente a compressão de contexto (Encoder) e a reconstrução espacial (Decoder).


Objetivo: Segmentação Densa

Diferente da classificação (uma label por imagem), a U-Net classifica cada pixel individualmente, essencial para delinear tumores ou estradas.

O Pulo do Gato: Skip Connections

Atalhos horizontais transportam mapas de alta resolução do Encoder diretamente para o Decoder, recuperando detalhes finos perdidos no downsampling.

U-Net: Conceito



U-Net: Encoder

1. Convolução Dupla

Cada nível aplica duas convoluções 3x3 seguidas de ativação ReLU. Isso extrai características locais não-lineares.

2. Max Pooling

Operação de Max Pooling 2x2 com stride 2 reduz a dimensão espacial pela metade, forçando a rede a aprender abstrações mais robustas.

3. O Que se Ganha?

A cada passo de downsampling, o número de canais de features dobra, capturando o contexto semântico ("o que é") em detrimento da localização ("onde está").

U-Net: Decoder

1. Upsampling

Usa "Transposed Convolution" (ou interpolação) para duplicar o tamanho espacial do mapa de características, revertendo o downsampling.

2. Concatenação

O mapa expandido é concatenado com o mapa correspondente do Encoder (via Skip Connection), fundindo contexto global com detalhes locais preservados.

3. Refinamento

Novas convoluções processam essa fusão para suavizar artefatos de upsampling e refinar a precisão da segmentação.

U-Net: Conexões de Skip

A Ponte

Conectam diretamente camadas de mesma resolução do Encoder para o Decoder, "pulando" o gargalo central da rede.

Recuperação

Permitem que o Decoder "veja" bordas e texturas originais que foram perdidas durante as operações de Max Pooling no Encoder.

Fluxo

Ajudam no fluxo de gradientes durante o backpropagation, mitigando o problema do desaparecimento de gradientes em redes profundas.

U-Net: Losses e Métricas

O maior desafio em segmentação é o desbalanceamento de classes (ex: 99% fundo, 1% objeto de interesse).

Dice Loss

Otimiza diretamente a sobreposição entre a previsão e a máscara real, sendo robusta ao desbalanceamento.

Focal Loss

Evolução da Cross-Entropy que reduz o peso dos exemplos fáceis (fundo) e foca nos difíceis (bordas).

IoU (Jaccard)

Intersection over Union:
A métrica padrão ouro para avaliar a qualidade geométrica da segmentação.

Clássico vs Profundo: Comparação Geral

Critério	Clássico	CNNs	Transformers
Dados Necessários	Baixo	Médio	Altíssimo
Custo Computacional	Muito Baixo	Médio	Alto
Viés Indutivo	Manual	Forte (Localidade)	Fraco (Global)

Comparação por Tarefa

Classificação Massiva

ViT domina quando treinado em datasets gigantes (JFT, ImageNet-21k), superando ResNets em acurácia top-1.

Tarefas Densas (Detecção)

Swin Transformer tornou-se o novo backbone padrão, oferecendo melhor contexto para detectar objetos pequenos e grandes simultaneamente.

Small Data (Medicina)

U-Net clássica ainda é imbatível. Transformers puros geralmente falham em generalizar com poucas imagens sem pré-treino massivo.

Mobile / Edge

CNNs eficientes (MobileNet, EfficientNet) ainda reinam devido à sua baixa latência e requisitos de memória otimizados para hardware.