



Transformações de Intensidades 3: suavização, aguçamento, filtros não lineares

Guillermo Cámara-Chávez

Filtragem com Preservação de Bordas



- Filtros estatísticos passa-baixas podem suprimir detalhes importantes da imagem
 - linhas finas,
 - cantos de objetos.
- Isso acontece porque não é levado em consideração se o pixel se encontra sobre uma borda


Filtragem com Preservação de Bordas



$$GB[I]_p = \sum_{q \in S} G_{\sigma}(\|p - q\|) I_q$$



normalized
Gaussian function




Filtragem com Preservação de Bordas



Gaussian Profile

$$G_{\sigma}(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{x^2}{2\sigma^2}\right)$$



Filtragem com Preservação de Bordas




Spatial Parameter




input

$$GB[I]_p = \sum_{q \in S} G_{\sigma}(\| \mathbf{p} - \mathbf{q} \|) I_q$$

size of the window



limited smoothing



strong smoothing

Filtragem com Preservação de Bordas




- Como definir o valor de σ
 - Depende da aplicação
 - Estratégia comum: proporcional ao tamanho da imagem
 - Exemplo, 2% da diagonal da imagem

Filtragem com Preservação de Bordas



- Máscaras de Kuwahara
 - Uma das primeira técnicas com preservação de bordas
 - Foi proposto em 1976
 - O filtro considera uma região quadrada de dimensão $(2k-1) \times (2k-1)$

Filtragem com Preservação de Bordas



Filtragem com Preservação de Bordas



- Máscaras de Kuwahara
 - A variância dos níveis de cinza para cada janela
 - O valor do pixel (x,y) é substituído pela média dos níveis de cinza da janela com menor variância

Filtragem com Preservação de Bordas



$K = 2$



$K = 3$








$K = 4$

Filtragem com Preservação de Bordas




- Máscaras de Tomati e Tsuji



Filtragem com Preservação de Bordas



- O borramento vem da média dos pixels de regiões próximas (bordas).




Same Gaussian kernel everywhere.

Filtragem com Preservação de Bordas



- Filtragem bilateral



Filtragem Bilateral



- A mesma idéia: média ponderada dos pixels

$$BF[I]_p = \overset{\text{new}}{\frac{1}{W_p}} \sum_{q \in S} \overset{\text{not new}}{G_{\sigma_s}(\|p - q\|)} \overset{\text{new}}{G_{\sigma_r}(|I_p - I_q|)} I_q$$

The equation is annotated with three components:

- normalization factor**: Points to the term $\frac{1}{W_p}$ with a pink arrow.
- space weight**: Points to the term $G_{\sigma_s}(\|p - q\|)$ with an orange arrow. Below this text is a 2D Gaussian kernel visualization.
- range weight**: Points to the term $G_{\sigma_r}(|I_p - I_q|)$ with a blue arrow. Below this text is a 1D Gaussian kernel visualization along the intensity axis I .


Filtragem Bilateral



- 1D image = line of pixels




- Better visualized as a plot



Filtragem Bilateral




Gaussian blur



Bilateral filter

[Aurich 95, Smith 97, Tomasi 98]




$$GB[I]_p = \sum_{q \in S} \underbrace{G_{\sigma}(\|p - q\|)}_{\text{space}} I_q$$

$$BF[I]_p = \underbrace{\frac{1}{W_p}}_{\text{normalization}} \sum_{q \in S} \underbrace{G_{\sigma_s}(\|p - q\|)}_{\text{space}} \underbrace{G_{\sigma_r}(\|I_p - I_q\|)}_{\text{range}} I_q$$

Filtragem Bilateral



$$BF[I]_p = \frac{1}{W_p} \sum_{q \in S} G_{\sigma_r}(\|p - q\|) G_{\sigma_i}(\|I_p - I_q\|) I_q$$



Filtragem Bilateral



$$BF[I]_p = \frac{1}{W_p} \sum_{q \in S} G_{\sigma_s}(\|p - q\|) G_{\sigma_r}(\|I_p - I_q\|) I_q$$

$$W_p = \sum_{q \in S} G_{\sigma_s}(\|p - q\|) G_{\sigma_r}(\|I_p - I_q\|)$$

Filtragem Bilateral



- Como definir os parâmetros
 - Parâmetro espacial: proporcional ao tamanho da imagem
 - Exemplo, 2% da diagonal da imagem
 - Parâmetro de intervalo de intensidade (*range parameter*): proporcional à amplitude das bordas
 - Exemplo, média ou mediana dos gradientes da imagem

Filtragem Bilateral



$\text{Sigma}_p = 7$


$\text{Sigma}_q = 9$

window = 3

Filtros Não Lineares



- Filtro da Moda
 - Consiste em substituir o pixel central P de $w \times w$ pelo NC mais freqüente na janela $w \times w$: a “moda”



A moda = 50 $\Rightarrow p(5) = 50$

Filtros Não Lineares



- Filtro da ordem k
 - Associam o k -ésimo valor dos NC's de uma janela $w \times w$ arranjados em ordem crescente.
 - Sejam :
 $p(1), p(2), \dots, p(E)$ os NC's dos elementos de w
 $z(1), z(2), \dots, z(E)$ os mesmos NC's arranjados em ordem crescente

Filtros Não Lineares



- Casos especiais:
 - $k = 1$ -> filtro min
 - $k = E$ -> filtro max
 - $k = (E+1)/2$ -> filtro da mediana
- Resultados apresentados na literatura mostram que os filtros de ordem maior que o filtro da mediana alargam regiões claras da imagem

Filtros Não Lineares



- Filtros MIN MAX
 - Generalizações de operadores de compressão e expansão para aplicação em imagens
 - São também indicados para remoção de ruído do tipo sal ou pimenta

Filtros Não Lineares



```
img = io.imread('lenna.png')
noise_img = util.random_noise(img, mode = 'p')
noise_img = img_as_ubyte(noise_img)
footprint = np.ones( (3,3) )
nimg = filters.rank.maximum(noise_img, footprint=footprint)
f, ax = plt.subplots(1,2,figsize=(16,16))
ax[0].imshow(noise_img, cmap='gray')
ax[1].imshow(nimg, cmap='gray')
```

Filtros Não Lineares



Filtros Não Lineares



- Filtro da mediana
 - Consiste em substituir o pixel central da janela $w \times w$ pelo valor de cinza media de da janela, cujos elementos foram ordenados.
 - Preserva, sem borrar, os contornos de regiões maiores que a janela usada.
 - Elimina descontinuidades que são menores que o tamanho da janela.

Filtros Não Lineares



$$W_{3 \times 3} = \begin{matrix} 11 & 50 & 49 \\ 10 & 80 & 52 \\ 10 & 51 & 50 \end{matrix}$$

em ordem crescente:

10 10 11 49 50 50 51 52 80

↑

Mediano = 50 $\rightarrow$ $p(5) = 50$

Filtros Não Lineares



```
noise_img = util.random_noise(lua, mode = 's&p')  
noise_img = img_as_ubyte(noise_img)  
nimg = filters.rank.median(noise_img, footprint=footprint)  
f, ax = plt.subplots(1,2,figsize=(16,16))  
ax[0].imshow(noise_img, cmap='gray')  
ax[1].imshow(nimg, cmap='gray')
```


Filtros Não Lineares



Realce (Sharpening)



- Tende a realçar mudanças abruptas de níveis de cinza na imagem.
- Esta operação é conhecida como “*edge enhancement*”, “*edge crispening*” ou “*unsharp masking*”.

Realce (Sharpening)




- Alguns exemplos de máscaras:

$$\begin{array}{ccc} \begin{array}{ccc} -1 & -1 & -1 \\ M_1 = & -1 & 9 & -1 \\ & -1 & -1 & -1 \end{array} & \begin{array}{ccc} 1 & -2 & 1 \\ M_2 = & -2 & 5 & -2 \\ & 1 & -2 & 1 \end{array} & \begin{array}{ccc} 0 & -1 & 0 \\ M_3 = & -1 & 5 & -1 \\ & 0 & -1 & 0 \end{array} \end{array}$$

Realce (Sharpening)



Conv. com a
máscara M_1



Conv. com a
máscara M_2




Conv. com a
máscara M_3

Realce (Sharpening)



- Outra forma de realçar uma imagem é através do seguinte método



Realce (Sharpening)



- A aplicação de um operador de “unsharp masking”, está constituído por uma seqüência de duas operações
 1. Obter uma versão suavizada da imagem
 2. Combinação entra a imagem original e o resultado da primeira operação

Realce (Sharpening)



$$f(x,y) = f_{\text{lowpass}}(x,y) + f_{\text{highpass}}(x,y)$$

O filtro da média é um filtro passa-baixas

$$f(x,y) = f_{\text{mean}}(x,y) + f_{\text{highpass}}(x,y)$$

$$f_{\text{highpass}}(x,y) = f(x,y) - f_{\text{mean}}(x,y)$$

Realce (Sharpening)



```
lua = io.imread(lua.png', as_gray=True)
w = np.array([[0, 1, 0], [1,-4, 1], [0, 1, 0]])
img_f = img_as_float(lua)
img_conv = ndimage.convolve(img_f, w)
nimg = img_f - img_conv
f, ax = plt.subplots(1,2,figsize=(10,10))
ax[0].imshow(img_f, cmap='gray', vmin=0, vmax=1)
ax[1].imshow(nimg, cmap='gray', vmin=0, vmax=1)
```

Realce (Sharpening)



Realce (Sharpening)



- Em alguns casos é interessante realçar as altas freqüências sem atenuar as baixas.
- Nesta situação é interessante adicionar uma quantidade proporcional de altas freqüências à imagem original adicionando um termo de ganho G

$$f_{\text{highpass}}(x,y) = (1+G).f(x,y) - G.f_{\text{mean}}(x,y), \text{ onde } 0 \leq G \leq 2$$

Realce (Sharpening)



- A máscara que implementa o método anterior é:

$$M = \begin{bmatrix} -G/9 & -G/9 & -G/9 \\ -G/9 & (9+8G)/9 & -G/9 \\ -G/9 & -G/9 & -G/9 \end{bmatrix}$$

Realce (Sharpening)




$G = 2$

Realce (Sharpening)



(a) Pixel values over an edge




(b) The edge blurred

Realce (Sharpening)



(a) Pixel values over an edge



(c) $(a) - k(b)$

Sinal realçado

Realce (Sharpening)



```
lua = io.imread('lua.png', as_gray=True)
lua_sharp = filters.unsharp_mask(lua, radius=4, amount=1.0)
f, ax = plt.subplots(1,2, figsize=(10,10))
ax[0].imshow(lua, cmap='gray')
ax[0].set_title('Original')
ax[1].imshow(lua_sharp, cmap='gray')
ax[1].set_title('Unsharp')
```


Métricas de Qualidade em Imagens



- Uma imagem pode sofrer degradações durante o processo de aquisição, transmissão ou processamento.
- Métricas de qualidade podem ser utilizadas para avaliar a similaridade entre duas imagens
- Considerando duas imagens, f e g , ambas com dimensões $M \times N$

Métricas de Qualidade em Imagens



- Erro máximo (ME, do inglês, *Maximum Error*)

$$ME = \max | f(x, y) - g(x, y) |$$

- Quanto menor essa métrica, melhor a nova imagem se aproxima da original
- É bastante sensível ao ruído ou a variações locais nas imagens

Métricas de Qualidade em Imagens



- Erro médio absoluto (MAE, do inglês, *Mean Absolut Error*)

$$MAE = \frac{1}{MN} \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} |f(x, y) - g(x, y)|$$

— Quanto menor essa métrica, melhor a nova imagem

Métricas de Qualidade em Imagens



- Erro médio quadrático (MSE, do inglês, *Mean Square Error*)

$$MSE = \frac{1}{MN} \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (f(x, y) - g(x, y))^2$$

— Quanto menor essa métrica, melhor a nova imagem

Métricas de Qualidade em Imagens



- Raiz do erro médio quadrático (RMSE, do inglês, *Root Mean Square Error*)

$$MSE = \sqrt{\frac{1}{MN} \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (f(x, y) - g(x, y))^2}$$

— Uma variação do erro mínimo quadrático

Métricas de Qualidade em Imagens



- Erro médio quadrático normalizado (NMSE, do inglês, *Normalized Mean Square Error*)

$$NMSE = \frac{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (f(x, y) - g(x, y))^2}{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (f(x, y))^2}$$

- Valores variam entre 0 e 1, o que torna possível a avaliação de imagens com dimensões diferentes

Métricas de Qualidade em Imagens



- Relação Sinal-Ruído de Pico (PSNR, do inglês, *Peak Signal to Noise Ratio*)

$$PSNR = 10 \log_{10} \frac{(L_{\max})^2}{RMSE} = 10 \log_{10} \frac{MNL_{\max}^2}{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (f(x, y) - g(x, y))^2}$$

— Avalia a diferença global entre duas imagens

Métricas de Qualidade em Imagens



- L_{max} é o valor máximo de intensidade cinza, tipicamente $L_{max} = 255$
- Quanto maior esse métrica, melhor a nova imagem
- Relação sinal-ruído (SNR, do inglês, Signal to Noise Ratio)

$$SNR = 10 \log_{10} \frac{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (f(x, y))^2}{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (f(x, y) - g(x, y))^2}$$

Métricas de Qualidade em Imagens



- Covariância

$$\sigma_{fg} = \frac{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (f(x, y) - \mu_f)(g(x, y) - \mu_g)}{MN}$$

onde μ_f e μ_g representam o nível de cinza média nas imagens ***f*** e ***g***

— está relacionada com a presença, ou não, de redundância de informação entre duas imagens

Métricas de Qualidade em Imagens



- Coeficiente de correlação
 - O valor varia entre -1 a 1, valores próximos de 0 representam um relacionamento linear mais fraco

$$\sigma_{fg} = \frac{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (f(x, y) - \mu_f)(g(x, y) - \mu_g)}{\sqrt{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (f(x, y) - \mu_f)^2 \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (g(x, y) - \mu_g)^2}}$$